

Clasificación multimodal de esperanza de vida con robustez ante datos faltantes

ARA

Máster en Inteligencia Artificial, Reconocimiento de Formas e Imagen Digital
Universitat Politècnica de València

Miquel Gómez Corral · Andrés Pacheco Millán

- ❶ Introducción y motivación
- ❷ Trabajo relacionado
- ❸ Descripción de la tarea
- ❹ Dataset
- ❺ Arquitectura del modelo
- ❻ Nuestras contribuciones
- ❼ Diseño experimental
- ❽ Resultados
- ❾ Conclusiones y trabajo futuro

Introducción y motivación

En la práctica clínica **rara vez se dispone de todos los datos** de un paciente al momento de decidir.

¿Por qué faltan datos?

- Urgencia o coste: no siempre hay tiempo o recursos para todas las secuencias MRI
- Fallos técnicos o paciente no colaborador
- Registros incompletos o perdidos


Objetivo

Predecir la esperanza de vida en glioblastoma con un modelo **robusto ante datos faltantes**.

Dataset UPenn-GBM

Variable	Valor
Pacientes / muestras	603 / 630
Edad media	62.7 ± 12.5 años
Género (M / F)	378 / 252
Supervivencia media	496 días
Clase 0 ($\leq 12m$)	305
Clase 1 ($> 12m$)	339

Split	Pacientes	%
Entrenamiento	482	80 %
Validación	60	10 %
Test	61	10 %



MRI 3D

Procesadas: Alineadas y sin cráneo

T1: Anatomía estructural sana

T1ce: Tumor activo

T2: Contenido de agua / líquido

FLAIR: Edema peritumoral

Descripción de la tarea

Clasificación binaria de supervivencia

- **Clase 1** — supervivencia > 12 meses
- **Clase 0** — supervivencia ≤ 12 meses

Tres modalidades de entrada

- **MRI 3D**: 4 secuencias T1, T1Gd, T2, FLAIR
- **Clínicos**: edad, género, KPS, IDH1, MGMT, GTR
- **Radiómicos**: 144 *features* por región ED, ET, NC

El reto central

En inferencia, **cualquier combinación de estas entradas puede estar ausente**. El modelo debe funcionar bien en todos los casos, sin lógica condicional codificada a mano.


Trabajo relacionado

Gomaa et al. (2024)

Comprehensive multimodal deep learning survival prediction enabled by a transformer architecture

- Dos vistas con *cutout* y *patch-swapping*
- Pretraining auto-supervisado:
 - ▶ *Contrastive Learning*: ambas representaciones similares entre sí
 - ▶ *Context Reconstruction*: capacidad de reconstruir la imagen original
- **Cross-attention** entre características fisiológicas y características extraídas del ViT

Punto de partida: tomamos esta arquitectura y la extendemos para **tolerar datos faltantes** e incorporar radiómicos como nueva modalidad.



Arquitectura original de Gomaa et al. (2024).


Arquitectura — Propuesta inicial

Fusión vía Cross-Attention

- Radiómicos atienden a características del ViT

Limitaciones

- Radiómicos extraídos **de la segmentación**: información redundante con la imagen MRI
- Sin imagen, el cross-attention **no tiene tokens** a los que atender → el módulo colapsa
- La fusión no distingue si una modalidad **falta o está presente**



Cross-attention entre imagen (azul) y clínicos (morado).

Arquitectura — Gated Fusion


Puerta lógica por dimensión

- Sigmoid **por dimensión**: cada canal aprende a incluirse o excluirse
- Si falta alguna modalidad, el gate aprende a **anularla**

$$h = (1 - \sigma) \odot r + \sigma \odot v$$

Ventajas

- Tolera ausencia de modalidades sin degradar el pipeline
- El gate aprende a ignorar redundancia imagen-radiómicos
- Añade modalidad nueva sin romper la arquitectura base



Gated Fusion (verde) integra radiómicos antes del cross-attention.

Nuestras contribuciones

Robustez ante datos faltantes

- **Data dropout**: simulación sistemática de ausencias durante el entrenamiento
- El modelo aprende a funcionar con **cualquier combinación** de modalidades

Resultado

El modelo acepta **cualquier combinación de entradas** en inferencia, sin necesidad de reentrenar.

Nueva modalidad: radiómicos

- Gestionados por un **sigmoid gate**: el modelo decide cuándo y cuánto usarlos
- Si la modalidad falta, el gate la anula automáticamente

Dataset Extra: BraTS 2021

Variable	Valor
Pacientes	1251
Secuencias MRI	4 (T1, T1ce, T2, FLAIR)
Preprocesado	Alineado, sin cráneo
Segmentación	Disponible (no usada)

- Tiene el mismo formato: También está sin cráneo.
- Contiene $\times 2$ datos que UPenn + diversidad multi-institucional
- Mejor representación espacial y generalización.

Autosupervisado — sin etiquetas

Las anotaciones expertas (necrosis, edema, tumor activo) **se descartan** en SSL. El ViT aprende geometría y texturas cerebrales sin supervisión humana.

Fase 1 — Pretraining SSL

- *Contrastive learning* y *Context reconstruction*
- BraTS 2021: 1251
- Upenn-GBM.

Fase 2 — Clasificación

- ViT congelado, 5 épocas
- Pocas épocas para evitar que el modelo sobreajuste en validación

Simulación de datos faltantes

- MRI y radiómicos: $\sim 40\%$ de ausencia por canal
- Tabulares: $\sim 20\%$ de ausencia por feature

Estrategia train vs. test

Dynamic dropout en entrenamiento: tasa variable para mejorar robustez. *Static dropout* fijo en test para garantizar reproducibilidad.


Máscara	Radiómicos	F1
All	No	0.660
Test	Sí	0.656
All	Sí	0.652
Train	No	0.645
Test	No	0.622
Train	Sí	0.605
None	No	0.616
None	Sí	0.603

La combinación **All No** obtiene el mejor F1 (0.660) en BraTS.

Máscara	Radiómicos	F1
All	No	0.639
All	Sí	0.621
Test	No	0.607
None	Sí	0.607
Train	No	0.605
Test	Sí	0.587
None	No	0.567
Train	Sí	0.565


La combinación **All No** obtiene el mejor F1 (0.639) en UPenn.

Ablación — Contribución de cada modalidad




- Sin tabulares: **notable caída de F1**. Modalidad más crítica
- Entrenar con radiómicos **mitiga** la falta de clínicos
- Predecir con radiómicos **empeora**: el gate no los suprime
- Entrenar con dropout **mejora** en la mayoría de configuraciones


Ablación — BraTS, All Masks




Ablación — BraTS, Sin Máscaras



Ablación — UPenn, All Masks



Ablación — UPenn, Sin Máscaras



Conclusiones y trabajo futuro

Conclusiones

- ➊ Modelo multimodal capaz de integrar MRI, datos clínicos y radiómicos de forma conjunta
- ➋ El modelo es robusto ante datos faltantes
- ➌ Se alcanza un F1 comparable al baseline pese a la mayor complejidad del problema
- ➍ El estudio ablacional confirma que los datos clínicos son la modalidad más crítica, y que los radiómicos mitigan su ausencia

Trabajo futuro

- ➊ Explorar mecanismos de fusión que superen el *gated fusion* actual
- ➋ Estudiar si el *gate* aprende a suprimir los radiómicos en inferencia cuando no aportan información adicional a la imagen
- ➌ Ampliar la tarea a regresión de supervivencia
- ➍ Validar el modelo en centros externos para comprobar la generalización

Aporte principal

El principal aporte no es superar el estado del arte, sino demostrar que un único modelo puede tolerar ausencias arbitrarias de modalidades de forma aprendida, lo que lo hace directamente aplicable al entorno clínico real.

¿Preguntas?

Miquel Gómez Corral · Andrés Pacheco Millán

Máster en Inteligencia Artificial, Reconocimiento de Formas e Imagen Digital
Universitat Politècnica de València