

Clasificación Multimodal de Esperanza de Vida con Robustez ante Datos Faltantes

ARA — Aprendizaje y Reconocimiento de Patrones

Máster en Inteligencia Artificial, Reconocimiento de Formas e Imagen Digital
Universitat Politècnica de València

Miquel Gómez Corral · Andrés Pacheco Millán

- ➊ Introducción y motivación
- ➋ Trabajo relacionado
- ➌ Descripción de la tarea
- ➍ Modalidades de entrada
- ➎ Arquitectura del modelo
- ➏ Nuestras contribuciones
- ➐ Diseño experimental
- ➑ Resultados
- ➒ Discusión
- ➓ Conclusiones y trabajo futuro

El problema: predecir sin tener todos los datos


En la práctica clínica **rara vez se dispone de todas las pruebas** de un paciente al momento de decidir.

¿Por qué faltan datos?

- Urgencia: no hay tiempo para todas las secuencias MRI
- Fallos de equipamiento o captura
- Paciente inestable o no colaborador
- Coste económico de pruebas adicionales
- Registros incompletos o perdidos

Objetivo

Predecir la esperanza de vida en glioblastoma con un modelo **robusto a cualquier patrón de datos faltantes**, sin reentrenar.



*MRI 3D multimodal — glioblastoma
(UPenn-GBM)*

Pregunta clave

¿Qué datos son *realmente* imprescindibles para un buen diagnóstico?

Punto de partida: Gomaa et al. (2024)

Comprehensive multimodal deep learning survival prediction enabled by a transformer architecture

Arquitectura propuesta

- ViT 3D + *self-supervised pretraining* (contrastive + reconstruction)
- Fusión imagen↔clínica vía **cross-attention**
- 4 secuencias MRI + datos clínico-moleculares
- Validado en 3 centros independientes

Nuestra base: tomamos esta arquitectura y la extendemos para **tolerar datos faltantes** y aprovechar nuevas modalidades.

Resultados originales (test UPenn)

Datos	Modelo	C _{dt}
Clínicos	CoxPH	0.667
Clínicos	DeepSurv	0.644
Clínicos	Transformer	0.667
Imagen	ViT <i>end-to-end</i>	0.622
Imagen	Transformer + SSL	0.645
Combi.	CNN + CoxPH	0.671
Combi.	Transformer	0.707

La fusión multimodal **supera consistentemente** a cualquier modalidad por separado.

Dataset UPenn-GBM y tarea

Datos disponibles por paciente

- 4 secuencias MRI 3D: T1, T1Gd, T2, FLAIR
- Datos clínicos (edad, género, KPS, IDH1, MGMT, GTR)
- Características radiómicas extraídas de las MRI

Tarea: clasificación binaria

- **Clase 1** — supervivencia > 12 meses
- **Clase 0** — supervivencia ≤ 12 meses

Tras descartar visitas duplicadas: **630 muestras de 603 pacientes**. Clases prácticamente balanceadas.

Variable	Valor
Pacientes / muestras	603 / 630
Edad media	62.7 ± 12.5 años
Género (M / F)	378 / 252
Supervivencia media	496 días
IDH1 mutado / wildtype	19 / 514
MGMT metilado / no metilado	115 / 160
Resección total (GTR)	362 (57.5 %)
Clase 0 ($\leq 12m$)	305
Clase 1 ($> 12m$)	339


Complejidad

Dataset *moderado*, alta variabilidad biológica, múltiples fuentes heterogéneas.

Predecir un año de vida no es trivial.

Tres modalidades, una arquitectura

Imagen MRI 3D



- 4 canales: T1, T1Gd, T2, FLAIR
- Volumen reducido a 96^3 vóxeles (memoria / cómputo)
- **Salida:** 217 tokens

Datos clínicos

- Género, edad, KPS
- IDH1, MGMT, GTR
- *One-hot* + normalización $[-1, 1]$
- **14 features**
- **Salida:** 8 tokens

Falta $\rightarrow$ cero + *bit flag* + *missing_emb* aprendido

Radiómicos

- 144 *features* por (región, modalidad)
- 3 regiones: ED, ET, NC
- 4 modalidades MRI
- **Salida:** 12 tokens

Complementan la imagen cuando faltan canales MRI

*El paper original descartaba los radiómicos por considerarlos ruido. Nosotros los incorporamos como modalidad complementaria gestionada por un **sigmoid gate**.*


Arquitectura: visión general

Fase 1 — Pretraining auto-supervisado

- Dos vistas aumentadas del mismo volumen
- *Contrastive loss* (NT-Xent) + *context reconstruction*
- Sobre BraTS (1 251 vol.) o UPenn (603 vol.)

Fase 2 — Clasificación binaria

- Encoder ViT congelado → *tokens* de imagen
- Fusión con radiómicos vía **sigmoid gate**
- **Cross-attention** bidireccional imagen ↔ clínicos
- *Attention pooling* + clasificador binario



Cómo manejamos los datos faltantes

Sigmoid gate (radiómicos $\leftrightarrow$ imagen)

$$\sigma = \text{sigmoid}(W [\text{img}; \text{rad}])$$

$$\text{fused} = \text{img} \odot \sigma + \text{rad} \odot (1 - \sigma)$$

Decide **por token y por dimensión** cuánta información radiómica incorporar.

Si los radiómicos faltan $\rightarrow \text{rad} \approx 0 \rightarrow \sigma \rightarrow 1$
 $\rightarrow$ imagen pura, sin código condicional.

Cross-attention bidireccional

Cada modalidad se enriquece atendiendo a la otra.
Pooling final + MLP de clasificación.

Sin ramas if: todo vía máscaras aprendidas

`missing_emb` *embedding* aprendido que
sustituye *features* tabulares
ausentes

`image_mask_proj` inyecta la presencia/ausencia
de canales MRI directamente en el
gate

Máscaras de radiómicos tokens inválidos $\rightarrow$ cero,
ignorados por *mean pool*

Principio de diseño

El modelo aprende **qué hacer cuando algo falta**, en vez de seguir reglas codificadas a mano.

Nuestras contribuciones sobre el paper base

Robustez ante datos faltantes

- **Data dropout**: simulación sistemática de ausencias durante el entrenamiento (MRI, tabular, radiómicos)
- **Mask wiring**: el modelo *sabe qué falta* vía `missing_emb` e `image_mask_proj`
- Manejo de ausencias **sin condicionales**: máscaras + *gates* aprendidos

Nueva modalidad

- **Radiómicos** como complemento (no ruido): el *sigmoid gate* decide cuándo y cuánto usarlos

Mejor representación de la imagen

- **Embeddings posicionales 3D**: rejilla 6^3 aprendida que preserva la localidad espacial
- **Pretraining con BraTS** (1 251 vol.) para diversificar el SSL
- Aumentaciones de intensidad adaptadas al dominio BraTS

Adaptación de la tarea

- Clasificación binaria a 12 meses (en lugar de curva de supervivencia)

Resultado

El modelo generaliza a cualquier patrón de datos faltantes en inferencia, sin reentrenar

Diseño experimental

Partición de datos (UPenn-GBM)

Conjunto	Pacientes	%
Entrenamiento	482	80 %
Validación	60	10 %
Test	61	10 %

Simulación de datos faltantes

- MRI: $\sim 5\%$ por canal
- Radiómicos: $\sim 10\%$ por región
- Tabulares: $\sim 10\%$ por grupo

Dynamic dropout en *train*; *static dropout* fijo en *test* (reproducible).

Entrenamiento en dos fases

1. Pretraining SSL

- BraTS (1 251 vol.) o UPenn (603 vol.)
- *Batch* 32, AdamW $lr = 10^{-4}$, 20–50 épocas
- Aumentaciones: *flip*, *rotate*, *noise*, *crop*, *patch swap*, *cutout*

2. Clasificación de supervivencia

- ViT congelado
- *Label smoothing* 0.1
- *Cosine annealing* + *early stopping*
- *Batch* 16, AdamW $lr = 10^{-4}$

Resultados — Ablación de mejoras

Paso	Cambio introducido	F1	Prec.	Rec.	Δ F1
0b	Baseline (UPenn SSL)	0.6518	0.6657	0.6557	—
1	+ <i>Mask wiring</i>	0.6382	0.6426	0.6393	−0.0136
3	+ Normalización tabular $[-1, 1]$	0.6407	0.6926	0.6557	−0.0111
5	+ <i>Embeddings</i> posicionales 3D (6^3)	0.6601	0.7057	0.6721	+0.0083
6	+ Aumentaciones de intensidad BraTS	0.6640	0.6946	0.6721	+0.0039

Mejora acumulada sobre el baseline

Métrica	Baseline	Final
F1	0.6518	0.6640 (+0.012)
Precisión	0.6657	0.6946 (+0.029)
Recall	0.6557	0.6721 (+0.016)

Observaciones clave

- Los *embeddings* 3D son la mejora individual de mayor impacto
- El *mask wiring* requiere más épocas para converger
- El SSL con BraTS pierde estabilidad pasadas ~ 20 épocas

Resultados — Efecto del *data dropout*

Dropout Train	Dropout Test	F1 (%)	F1 con radiómicos (%)
No	No	63.38	58.55
Sí	No	59.21	53.40
No	Sí	68.47	59.56
Sí	Sí	63.04	51.75

Lecciones sobre dropout

- *Dynamic dropout* en *train* introduce ruido excesivo y degrada el rendimiento
- Solo aplicarlo en test mejora el F1 hasta ~68 %
- El *batch size* 32 resulta crítico para el SSL contrastivo

El papel de los radiómicos

- Con datos completos añaden algo de ruido al modelo
- Con datos faltantes aportan **señal complementaria** — exactamente su rol diseñado
- La diferencia se reduce a mayor nivel de dropout

Nota: estos resultados corresponden a una versión previa del *split* y no son directamente comparables con la ablación anterior.

Discusión

Fortalezas

- Fusión multimodal $>$ cualquier modalidad por separado
- El *sigmoid gate* aprovecha los radiómicos sin degradar cuando faltan
- Los *embeddings* 3D mejoran la representación espacial del tumor
- Aceptamos *cualquier* combinación de entradas sin reentrenar
- El SSL sobre BraTS aporta diversidad de dominio

Debilidades

- El *dynamic dropout* en *train* es demasiado agresivo
- El SSL con BraTS colapsa pasadas ~ 20 épocas (loss contrastiva)
- Dataset modesto (482 train): generalización limitada
- La clasificación binaria descarta granularidad temporal
- *Mask wiring* converge lento — necesita más épocas

Hallazgo principal

No hacen falta ramas condicionales para manejar datos faltantes.

Máscaras aprendidas + *sigmoid gate* bastan para que la red

Conclusiones y trabajo futuro

Conclusiones

- ➊ Arquitectura multimodal robusta que integra MRI, radiómicos y datos clínicos
- ➋ Datos faltantes gestionados **sin condicionales**: máscaras + *gates* aprendidos
- ➌ Los radiómicos aportan señal complementaria cuando faltan canales MRI
- ➍ *Embeddings* posicionales 3D y aumentaciones BraTS mejoran la base
- ➎ Mejora acumulada de **+0.012 F1** sobre el baseline propio

Trabajo futuro

- ➊ Pretraining SSL con más datasets (UCSF-PDGM, RHUH)
- ➋ *Curriculum learning* sobre el dropout durante *train*
- ➌ Predicción de curva de supervivencia (DeepHit) en lugar de binaria
- ➍ Validación con datos reales de centros con ausencias auténticas
- ➎ Análisis de qué modalidades son verdaderamente imprescindibles
- ➏ Destilar el modelo para despliegue clínico eficiente

¿Preguntas?

Miquel Gómez Corral · Andrés Pacheco Millán

Máster en Inteligencia Artificial, Reconocimiento de Formas e Imagen Digital
Universitat Politècnica de València